

# 4. 모델 훈련

정윤서

## 4-1. 선형 회귀

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$$

- $\hat{y}$  : 예측값
- $n$  : 특성의 수
- $x_i$  :  $i$ 번째 특성값
- $\theta_j$  :  $j$ 번째 모델 파라미터(편향  $\theta_0$  와 특성의 가중치  $\theta_1, \theta_2, \dots$ , 포함)

## 4-1. 선형 회귀

$$\hat{y} = h_{\theta}(x) = \theta \cdot x$$

- $\theta$  : 편향  $\theta_0$ 와  $\theta_1$ 에서  $\theta_n$ 까지의 특성 가중치를 담은 모델의 파라미터 벡터
- $x$  :  $x_0$ 에서  $x_n$ 까지 담은 샘플의 특성 벡터.  $x_0$ 는 항상 1이다.
- $\theta \cdot x$  : 벡터 두 개의 점곱이다. 이는  $\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$ 와 같다.
- $h_{\theta}$  : 모델 파라미터  $\theta$ 를 사용한 가설 함수


# 4-1. 선형 회귀

## 1. 정규방정식

$$\hat{\theta} = (X^T X)^{-1} X^T y$$

- $\hat{\theta}$  : 비용함수를 최소화하는  $\theta$ 값
- $y$  :  $y(1)$ 부터  $y(m)$ 까지 포함하는 타깃 벡터

## 4-4. 학습 곡선



## 4-4. 학습 곡선

- 모델이 데이터에 과대/과소적합 되었는지 알아보는 방법
  - 교차 검증 → 2장에서 다루었음
  - **학습 곡선 살펴보기**
    - ✓ 훈련 세트와 검증 세트의 모델 성능을 훈련 세트 크기(또는 훈련 반복)의 함수로 나타낸다.
    - ✓ 단순히 훈련 세트에서 크기가 다른 서브 세트를 만들어 모델을 여러 번 훈련시키면 그래프를 생성할 수 있다.

## 4-4. 학습 곡선

- 단순 선형 회귀 모델(직선)의 학습 곡선




그림 4-15 학습 곡선

## 4-4. 학습 곡선

- 10차 다항 회귀 모델의 학습 곡선




그림 4-16 10차 다항 회귀의 학습 곡선



## 4-5. 규제가 있는 선형 모델

- 과대적합 감소시키는 방법

→ 규제

- 다항 회귀 모델

- ✓ 다항식의 차수 감소

- 선형 회귀 모델

- ✓ 가중치 제한

- ✓ 릿지 회귀, 라쏘 회귀, 엘리스틱넷

## 4-5.1. 릿지 회귀(티호노프 규제)

- 규제가 추가된 선형 회귀 버전
- $\alpha \sum_{i=1}^n \theta_i^2$  이 비용 함수에 추가됨
  - 학습 알고리즘을 데이터에 맞추는 것뿐만 아니라 모델의 가중치가 가능한 작게 유지되도록 노력함
  - 규제항은 훈련하는 동안에만 비용 함수에 추가됨
  - 모델의 성능은 규제가 없는 성능 지표로 평가

## 4-5.1. 릿지 회귀(티호노프 규제)

$$J(\theta) = MSE(\theta) + \alpha \frac{1}{2} \sum_{i=1}^n \theta_i^2$$

- $\alpha$  : 모델을 얼마나 많이 규제할지 조절
  - : 0이면 선형 회귀와 같아짐
  - : 아주 크면 모든 가중치가 거의 0에 가까워지고 결국 데이터 평균을 지나는 수평선이 됨

## 4-5.1. 릿지 회귀(티호노프 규제)

$$J(\theta) = MSE(\theta) + \alpha \frac{1}{2} \sum_{i=1}^n \theta_i^2$$

- $\theta_0$  : 규제되지 않음

: 합 기호가  $i=0$ 이 아니고  $i=1$ 에서 시작하기 때문

## 4-5.1. 릿지 회귀(티호노프 규제)

$$J(\theta) = MSE(\theta) + \alpha \frac{1}{2} \sum_{i=1}^n \theta_i^2$$

- $w$ 를 특성의 가중치 벡터( $\theta_1 \sim \theta_n$ )라고 정의하면 규제항은  $\frac{1}{2}(\|w\|_2)^2$ 와 같음
  - $\|*\|_2$ 는 가중치 벡터의 norm
  - 경사 하강법에 적용하려면 MSE 그래디언트 벡터에  $\alpha w$ 를 더하면 됨

## 4-5.1. 릿지 회귀(티호노프 규제)




그림 4-17 다양한 수준의 릿지 규제를 사용한 선형 회귀(왼쪽)와 다항 회귀(오른쪽).

## 4-5.1. 릿지 회귀(티호노프 규제)

- 정규 방정식

$$\theta = (X^T X + \alpha A)^{-1} X^T y$$

- A: 편향에 해당하는 맨 왼쪽 위의 원소가 0인  $(n+1) \times (n+1)$ 의 단위행렬

## 4-5.2. 라쏘 회귀

- 선형 회귀의 또 다른 규제된 버전

$$J(\theta) = MSE(\theta) + \alpha \sum_{i=1}^n |\theta_i|$$



## 4-5.2. 라쏘 회귀




그림 4-18 다양한 수준의 라쏘 규제를 사용한 선형 회귀(왼쪽)와 다항 회귀(오른쪽).

## 4-5.2. 라쏘 회귀




그림 4-19 라쏘 대 린지 규제

## 4-5.2. 라쏘 회귀

$$g(\theta, J) = \nabla_{\theta} MSE(\theta) + \alpha \begin{pmatrix} \text{sign}(\theta_1) \\ \vdots \\ \text{sign}(\theta_n) \end{pmatrix}$$

$$\text{sign}(\theta_i) = \begin{cases} -1 & \theta_i < 0 \\ 0 & \theta_i = 0 \\ 1 & \theta_i > 0 \end{cases}$$

## 4-5.3. 엘라스틱넷

- 릿지 회귀와 라쏘 회귀를 절충한 모델
- 규제항은 릿지와 회귀의 규제항을 단순히 더해서 사용
- 혼합 정도는 혼합 비율  $r$ 을 사용해 조절
  - $r=0$ 이면 릿지 회귀
  - $r=1$ 이면 라쏘 회귀

$$J(\theta) = MSE(\theta) + r\alpha \sum_{i=1}^n |\theta_i| + \frac{r-1}{2}\alpha \sum_{i=1}^n \theta_i^2$$

## 4-5. 규제가 있는 선형 모델

선형 회귀

릿지

라쏘

엘라스틱 넷

## 4-5.4. 조기 종료

- 검증 에러가 최솟값에 도달하면 바로 훈련을 중지시키는 것




그림 4-20 조기 종료 규제