


4장: 모델 훈련

4.2 경사하강법

4.3 다항회귀

4.6 로지스틱 회귀



4.2 경사하강법





옵티마이저

손실함수의 크기를 줄이는 것이 목표

- 어떻게 줄일 것인가? -> “옵티마이저”로 줄인다.

경사하강법은 곧 손실함수의 크기를 줄이는 옵티마이저의 일종

경사(기울기)를 구한다.



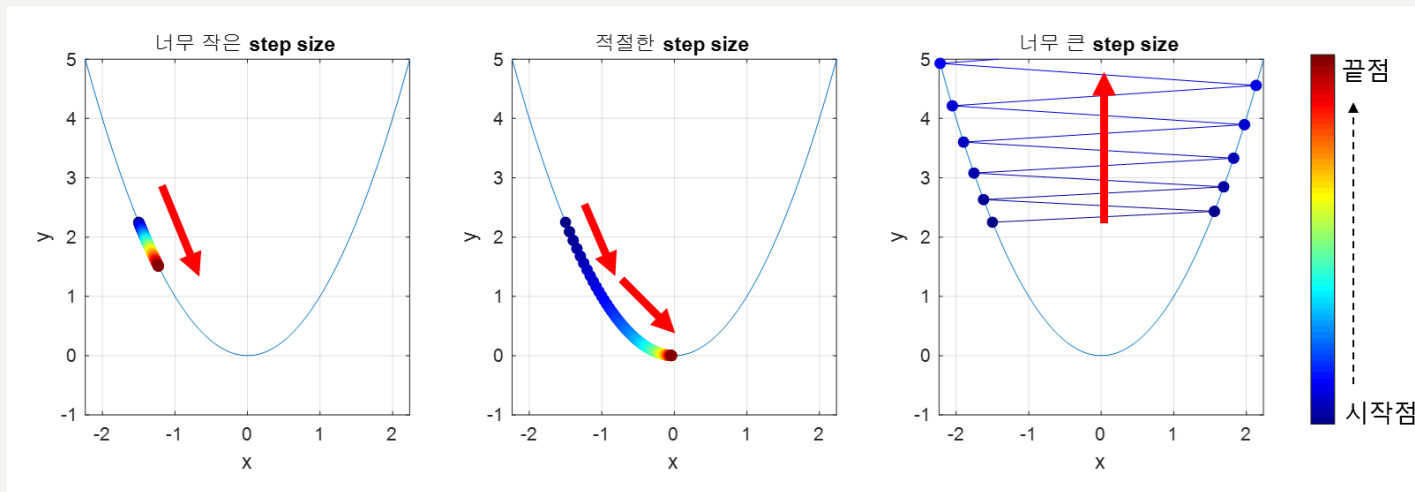
학습률 (스텝의 크기)

학습률이 너무 작다


-> 시간이 너무 오래 걸림

학습률이 너무 크다

-> 이상한 곳으로 발산 가능




경사하강법의 문제점



“무작위 초기화”로 인하여
지역 최소값에 수렴할 수 있다.

모멘텀 (Momenetum)




$$w_i^{k+1} = w_i^k + \eta \left(-\frac{d\epsilon}{dw_i^k} \right) + \alpha (\Delta w_i^{k-1})$$


α : Momentum term

모멘텀 + SGD

지그재그 현상을 줄여준다.




Stochastic Gradient
Descent **without**
Momentum



Stochastic Gradient
Descent **with**
Momentum

경사하강법의 문제점



- 변수들의 스케일이 매우 다를 경우 발생한다.

사이킷 런의 StandardScaler 활용

4.2.1 배치 경사 하강법

편도함수

$$\frac{\partial}{\partial \theta_j} \text{MSE}(\boldsymbol{\theta}) = \frac{2}{m} \sum_{i=1}^m (\boldsymbol{\theta}^T \mathbf{x}^{(i)} - y^{(i)}) x_j^{(i)}$$

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - t_i)^2$$

• θ_j 가 변함에 따라 비용함수가 변하는 정도 -> 편도함수

θ_j 에 대해 편미분..


$$\boldsymbol{\theta}^{(\text{next step})} = \boldsymbol{\theta} - \eta \nabla_{\boldsymbol{\theta}} \text{MSE}(\boldsymbol{\theta})$$

벡터화

$$\nabla_{\boldsymbol{\theta}} \text{MSE}(\boldsymbol{\theta}) = \begin{pmatrix} \frac{\partial}{\partial \theta_0} \text{MSE}(\boldsymbol{\theta}) \\ \frac{\partial}{\partial \theta_1} \text{MSE}(\boldsymbol{\theta}) \\ \vdots \\ \frac{\partial}{\partial \theta_n} \text{MSE}(\boldsymbol{\theta}) \end{pmatrix} = \frac{2}{m} \mathbf{X}^T (\mathbf{X}\boldsymbol{\theta} - \mathbf{y})$$

4.2.2 확률적 경사 하강법

- 매 스텝에서 한 개의 샘플을 무작위로 선택한다.




에포크와 배치 크기와 이터레이션 (Epochs and Batch size and Iteration)

에포크: 인공 신경망에서 전체 데이터에 대해서
순전파와 역전파가 끝난 상태

배치 크기: 몇 개의 데이터 단위로 매개변수를 업데이트
하는지

이터레이션(스텝): 한 번의 에포크를 끝내기 위해서
필요한 배치의 수



4.2.3 미니배치 경사 하강법

- “미니배치”에 대해 그래디언트를 계산한다.
- 미니배치: 임의의 작은 샘플 세트

4.3 다항회귀

VS

다중회귀

다항회귀

Simple
Linear
Regression

$$y = b_0 + b_1 * x_1$$

Multiple
Linear
Regression

Dependent variable (DV) Independent variables (IVs)

$$y = b_0 + b_1 * x_1 + b_2 * x_2 + \dots + b_n * x_n$$

Constant Coefficients

다중회귀



$$y = w_0 + w_1x + w_2x^2 + \dots + w_dx^d$$

4.6 로지스틱 회귀




이진 분류

score(x)	result(y)
45	불합격
50	불합격
55	불합격
60	합격
65	합격
70	합격




시그모이드 함수

$$H(x) = \frac{1}{1 + e^{-(wx+b)}} = \text{sigmoid}(wx + b) = \sigma(wx + b)$$



- 출력이 0과 1 사이의 값을 가지면서 s자 형태로 그려지는 함수
- w(weight), b(bias)

로지스틱 회귀의 비용함수



$$\text{if } y = 1 \rightarrow \text{cost}(H(x), y) = -\log(H(x))$$

$$\text{if } y = 0 \rightarrow \text{cost}(H(x), y) = -\log(1 - H(x))$$



$$\text{cost}(H(x), y) = -[y \log H(x) + (1 - y) \log(1 - H(x))]$$



$$J(w) = -\frac{1}{n} \sum_{i=1}^n [y^{(i)} \log H(x^{(i)}) + (1 - y^{(i)}) \log(1 - H(x^{(i)}))]$$

- MSE를 사용하지 않는다.
- 로그함수를 사용한다.

결론

- 로지스틱 회귀는 비용 함수로 크로스 엔트로피를 사용한다.
- 가중치를 찾기 위해서 크로스 엔트로피 함수의 평균을 취한 함수를 사용한다.

4.6.4

소프트맥스 회귀

다항 로지스틱 회귀라고도..

- 로지스틱 회귀 모델을 다중 클래스를 지원하도록 일반화

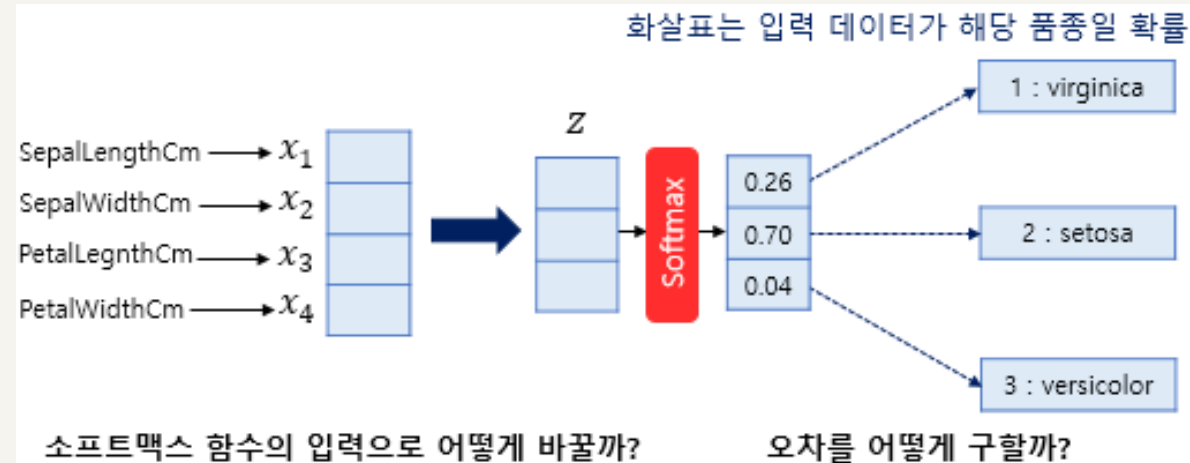
SepalLengthCm(x_1)	SepalWidthCm(x_2)	PetalLengthCm(x_3)	PetalWidthCm(x_4)	Species(y)
5.1	3.5	1.4	0.2	setosa
4.9	3.0	1.4	0.2	setosa
5.8	2.6	4.0	1.2	versicolor
6.7	3.0	5.2	2.3	virginica
5.6	2.8	4.9	2.0	virginica

소프트맥스 함수

$$p_i = \frac{e^{z_i}}{\sum_{j=1}^k e^{z_j}} \text{ for } i = 1, 2, \dots, k$$

$$\text{softmax}(z) = \left[\frac{e^{z_1}}{\sum_{j=1}^3 e^{z_j}}, \frac{e^{z_2}}{\sum_{j=1}^3 e^{z_j}}, \frac{e^{z_3}}{\sum_{j=1}^3 e^{z_j}} \right] = [p_1, p_2, p_3] = \hat{y} = \text{예측값}$$

$$\text{softmax}(z) = \left[\frac{e^{z_1}}{\sum_{j=1}^3 e^{z_j}}, \frac{e^{z_2}}{\sum_{j=1}^3 e^{z_j}}, \frac{e^{z_3}}{\sum_{j=1}^3 e^{z_j}} \right] = [p_1, p_2, p_3] = [p_{\text{virginica}}, p_{\text{setosa}}, p_{\text{versicolor}}]$$



크로스 엔트로피


- 비용함수

$$\text{softmax}(x) = \frac{e^{x_i}}{\sum_{j=0}^k e^{x_j}} \quad (i = 0, 1, \dots, k)$$

K = 2라면 로지스틱 회귀의 비용함수가 됩니다.


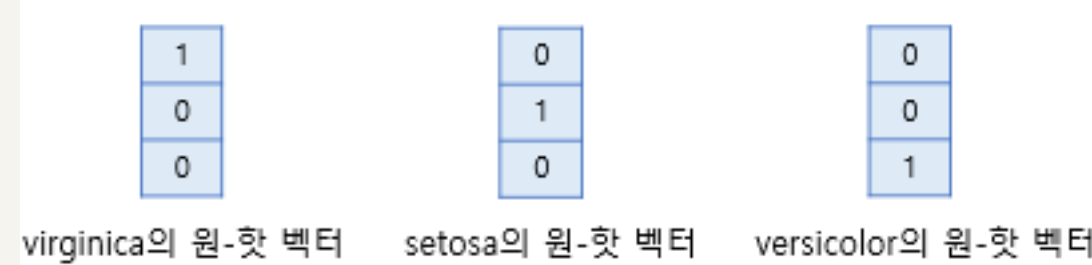
4개의 입력값

화살표는 입력 데이터가 해당 품종일 확률

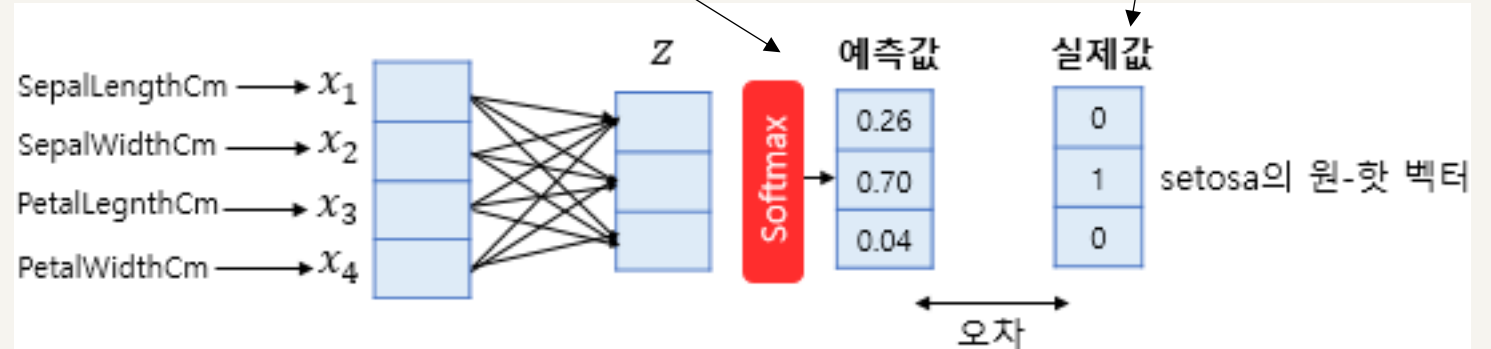


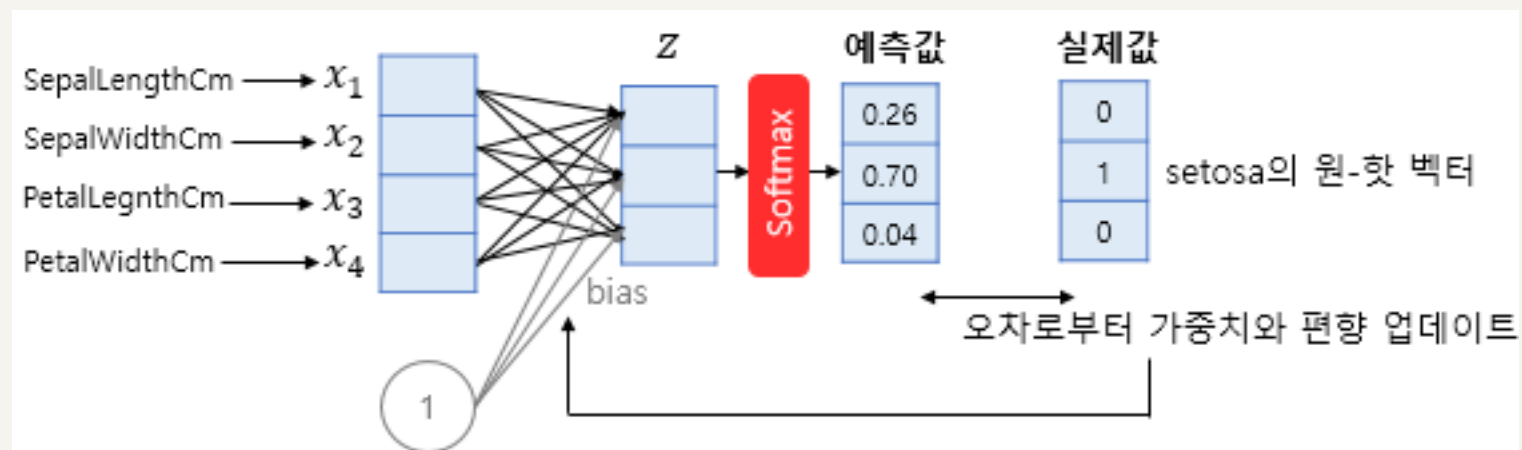
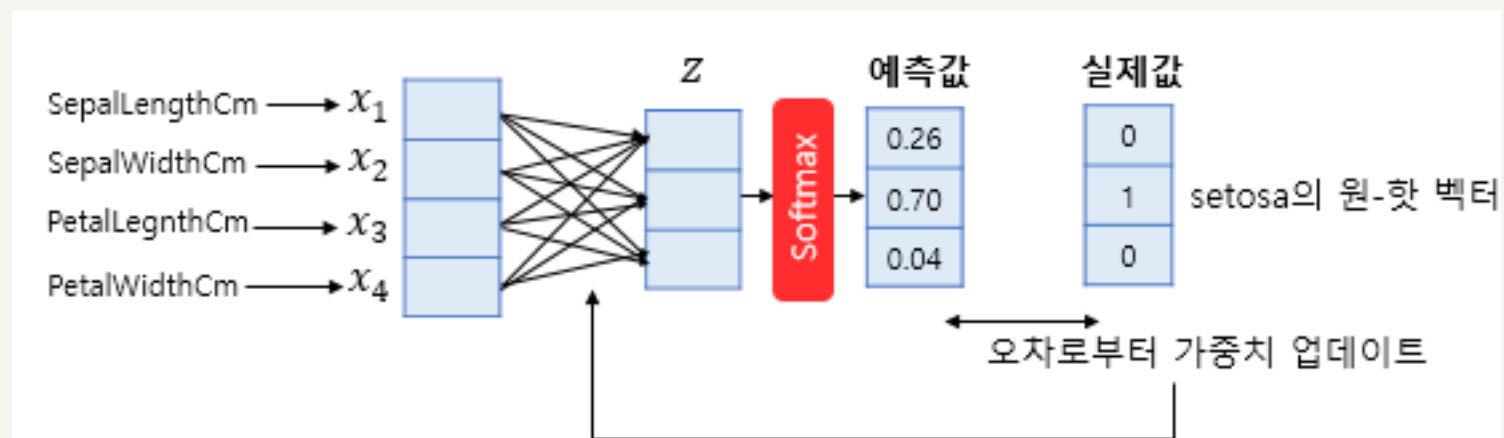
소프트맥스 함수의 입력으로 어떻게 바꿀까?

오차를 어떻게 구할까?



3차원 벡터로 변환





$$\text{softmax} \left(\begin{matrix} W \\ 3 \times 4 \end{matrix} \times \begin{matrix} x \\ 4 \times 1 \end{matrix} + \begin{matrix} b \\ 3 \times 1 \end{matrix} \right) = \begin{matrix} \text{예측값} \\ 3 \times 1 \end{matrix}$$

감사합니다.

